

中图法分类号: TP391 文献标识码: A 文章编号: 1006-8961(2018)02-0277-09

论文引用格式: Ma L, Liu R S, Jiang Z Y, Wang Y Y, Fan X, Li H J. Rain streak removal using learnable hybrid MAP network[J]. Journal of Image and Graphics, 2018, 23(2): 0277-0285. [马龙, 刘日升, 姜智颖, 王怡洋, 樊鑫, 李豪杰. 自然场景图像去雨的可学习混合 MAP 网络[J]. 中国图象图形学报, 2018, 23(2): 0277-0285.] [DOI:10.11834/jig.170390]

自然场景图像去雨的可学习混合 MAP 网络

马龙^{1,2}, 刘日升^{1,2}, 姜智颖^{1,2}, 王怡洋³, 樊鑫^{1,2}, 李豪杰^{1,2}

1. 大连理工大学—立命馆大学国际信息与软件学院, 大连 116621; 2. 辽宁省泛在网络与服务软件重点实验室, 大连 116621;

3. 大连理工大学数学科学学院, 大连 116024

摘要: 目的 近年来, 人工智能成为新兴研究领域, 得到越来越多研究机构的关注。图像恢复问题一直是低层次计算机视觉领域的一个研究热点, 其中, 图像去雨由于其雨线分布的未知性及其求解的病态性, 导致难以解决。现有方法存在雨线和背景之间的估计具有依赖性, 难以平衡雨线去除效果与估计背景的清晰程度之间的关系; 局限性比较大, 训练数据很难涵盖各种场景下的雨图, 而测试结果受训练数据的影响, 导致难于泛化。针对上述不足, 借鉴一般图像恢复问题思路, 将模型与以数据驱动的网络相结合, 凸显网络与模型各自的优势, 提出可学习的混合 MAP 网络有效地解决图像去雨问题。**方法** 首先基于最大后验估计 (MAP) 建立含有隐式先验的能量模型, 然后通过优化算法将模型分解为背景估计模型和雨线估计模型两部分, 以减少背景估计和雨线估计之间的依赖性。对于背景估计模型, 通过对模型及优化目标分析采用以数据驱动的去噪残差网络进行建模, 保证估计出的背景更清晰; 对于雨线估计模型, 为避免直接对未知的雨线建模失去准确性, 利用高斯混合模型实时刻画输入雨图的雨线先验。**结果** 在合成数据集 Rain12 及真实雨图上进行实验, 通过综合考虑定量分析和定性分析, 并与 3 种基于模型的方法及两种基于深度网络的方法相比, 本文方法在去除雨线的同时能够损失的背景信息最少, 合成数据集上的平均结构相似性 (SSIM) 值达到 0.92。**结论** 本文通过将基于模型的方法与基于深度网络的方法相结合, 既去除了雨线又保证了估计背景的清晰程度, 同时也验证了将传统模型与深度网络相结合是一种解决图像恢复问题的有效途径。

关键词: 图像去雨; 可学习混合 MAP 网络; 最大后验估计; 高斯混合模型; 残差网络

Rain streak removal using learnable hybrid MAP network

Ma Long^{1,2}, Liu Risheng^{1,2}, Jiang Zhiying^{1,2}, Wang Yiyang³, Fan Xin^{1,2}, Li Haojie^{1,2}

1. DUT-RU International School of Information Science & Engineering, Dalian University of Technology, Dalian 116621, China;

2. Key Laboratory for Ubiquitous Network and Service Software of Liaoning Province, Dalian 116621, China;

3. School of Mathematical Sciences, Dalian University of Technology, Dalian 116024, China

Abstract; Objective In recent years, artificial intelligence has become the emerging area and attract the attention of many research institutions. Computer vision is the force at the core of the development in the area of artificial intelligence. Image

收稿日期: 2017-07-29; 修回日期: 2017-09-27; 预印本日期: 2017-10-08

基金项目: 国家自然科学基金项目 (61672125, 61300086, 61572096, 61432003, 61632019); 中央高校基本科研基金项目 (DUT2017TB02); 香江学者计划基金项目 (XJ2015008)

第一作者简介: 马龙 (1994—), 男, 大连理工大学—立命馆大学国际信息与软件学院硕士研究生, 主要研究方向为图像处理。

E-mail: malone94319@gmail.com

通信作者: 刘日升, 副教授, E-mail: rslu@dlut.edu.cn

Supported by: National Natural Science Foundation of China (61672125, 61300086, 61572096, 61432003, 61632019)

restoration remains an active research topic in low-level computer vision. Because the distribution of the rain streaks is irregular and the problem is ill-posed, rain removal for the single image is one of the difficult problems to be solved. So far, the basic idea to solve the problem is building the rational rain image generative model, and find the solution by different measures. There are two representative ways. One is by describing the priors of rain streaks and background with conventional models and then solve it by the optimization algorithm, but the shortcoming is due to the interdependent connection between rain streaks and the background, it is hard to balance the relationship between the performance of rain removal and the clarity of background. The other is deep neural network based framework to build the network structure and loss function, then learning the network with large amounts of data, but the shortcoming is the difficulty of generalization because of test results are subject to the training data which is hard to cover the rain in the different scene. **Method** For the shortcomings mentioned above, inspired by general image restoration, this paper combines the network by data-driven with the empirical model, and the process displays the advantages of the network and empirical model, then learnable mixture MAP network is proposed so that image deraining problem can be solved effectively. The specific process is to build the energy model which contains the implicit prior item based on maximum a posteriori (MAP) framework, then transfer the model to two parts that is estimating background and estimating rain streaks by the optimization algorithm, and that reduce the dependency of background and rain streaks. For the first part, it can be solved by the residual network for denoising by analysis the model and the optimization objective and in this way, the estimated image is more clearly. For the second part, the rain streaks prior to the input image can be described real-time by gaussian mixture model to improve the accuracy of estimating rain streaks. **Result** In the end, compared with the three empirical model-based algorithms and two deep learning-based algorithms, the experiments on the synthetic dataset and real-world image demonstrate the good performance of our model on removing rain streaks meanwhile reducing the information loss of the background, in addition, the SSIM value reaches to 0.92 on the synthetic dataset. **Conclusion** This paper proposes to combine model-based method with deep network-based method, assimilates the advantages from each other. Not only can the majority of visible rain streaks be removed, but also remains detail information of background. Achieving a harmonious of the two aspects and standing out from state-of-the-art methods. At the same time, this paper makes a verification, which is the effective way to solve the image restoration problem by combining the conventional model and deep network.

Key words: image deraining; learnable hybrid MAP network; maximum a posteriori estimate; gaussian mixture model; residual network

0 引言

随着人工智能的发展,各种户外场景下的高科技应用层出不穷,如自动驾驶、交通监控等等。一般情况下,这些处理图像问题的应用需要的输入图像是清晰干净的,这样才能提取出正确的信息进行处理。然而现实生活中往往会存在种种干扰因素,导致获取到的图像是退化的,可视效果差,包含的真实图像信息少,无法经过处理得到好的结果,其中雨是最常见的一项天气干扰。所以去雨问题的研究对于户外场景下的与图像相关的应用而言,是具有重要价值的。

目前解决图像去雨问题的研究主要分为两类,一类是从模型角度出发^[1-5],这类方法注重于利用传统的模型来分别刻画雨线和背景图像两部分,并

通过相关优化算法将整个转化为迭代过程,迭代计算求解;另一类是基于深度学习思想^[6-8],构建网络框架来解决图像去雨问题。

最早提出利用模型进行图像去雨的是 Kang 等人^[1]提出的首先利用双边滤波将图像的高频成分和低频成分分解出来,分解出的低频成分主要包含背景图像的大部分信息,而高频成分主要包含背景图像的纹理信息及雨线信息,然后针对高频成分,使用 HOG(histogram of oriented gradient)特征,利用基于字典学习的稀疏编码将高频成分中的背景图像的纹理信息提取出来并与低频成分结合得到最终的背景图像的估计。虽然整个方法的思想有一定的启发性,但此方法得到的结果是比较模糊的。Luo 等人^[4]提出利用判别稀疏编码来分离雨图中的雨线和背景图像,实验表明虽然估计出的背景图像清晰,但雨线去除效果并不是很好。Chen 等人^[2]提出通

过低秩模型刻画雨线, 同时将 TV 模型作为背景图像的约束来建立去雨模型。Kim 等人^[3]首先利用核回归的方法来检测雨线, 然后再利用非局部均值滤波的方法去除检测到雨线区域的雨线。随着研究的深入, 以及对真实雨图的认识, 研究者们发现下雨的同时将伴随着不同程度的雾的生成, 而雾也将影响估计出的背景图像的可视效果。Li 等人^[5]基于块学习的思想利用高斯混合 (GMM) 模型来分别刻画背景层和雨层的先验知识, 然后该文章又通过组合去雾方法验证了该方法在实际去雨情况下的有效性, 该方法虽得到了目前为止模型中最好的结果, 但其估计的背景图像部分细节信息缺失导致图像不清晰。

与应用模型解决去雨问题相比, 应用深度学习框架来解决去雨问题是近几年才开始兴起的研究。Fu 等人^[6]基于深度卷积神经网络框架提出一种 DerainNet 去雨网络, 并考虑了雨带来的雾的影响, 在去雨之后增加去雾过程, 此外, Fu 等人^[8]通过对深度残差网络的学习形式进行简化, 提出了一种深度细节网络来解决去雨问题, 并且通过在去噪等问题上的应用证明了该网络框架的处理能力。Yang 等人^[7]提出对雨图中的雨线区域进行检测, 针对不同程度的雨线进行不同程度的去除操作, 设计了一种多任务的深度网络递归地进行雨线的检测和去除。他们还考虑到雾对视觉效果的影响, 并提出使用去雨—去雾—去雨的框架联合去除雨和雾^[8], 实验证明他们的方法对暴雨的情况尤为有效。

通过上述工作可以发现, 利用模型进行图像去雨带来的问题是, 无法平衡雨线去除效果与背景估计清晰程度之间的关系, 当雨线去除的相对干净时, 容易造成估计出的背景图像被平滑变得模糊。而基于深度学习思想构建不同目标的神经网络框架, 测试结果受训练数据分布影响, 而雨线分布收许多因素影响导致很难确定, 训练数据只能反映一部分的雨图情况, 所以很难泛化。但对比之下可以发现, 基于模型的算法一方面具有一定的泛化能力, 与数据无关, 能够解决雨线分布难以确定这一问题, 而基于深度学习的方法则一定程度上能够保证数据的本质特征。

针对图像去雨问题, 提出可学习的混合 MAP (maximum a posterior) 网络, 综合考虑模型与网络各自的优势, 有效地将模型与网络相结合。具体思路

为, 首先基于最大后验估计建立去雨问题的能量模型, 然后利用优化算法将模型分解为背景估计模型和雨线估计模型两部分, 由于背景估计模型与基本图像恢复问题图像去噪公式形式和目标相同, 因此利用去噪残差网络对该问题求解, 对于雨线估计模型, 利用高斯混合模型对雨线先验进行建模。这样一来, 不仅降低了雨线和背景之间的依赖程度, 而且使问题得到了简化, 此外, 利用去噪残差网络来解决背景估计部分将问题进一步简化。

1 基于最大后验估计的图像去雨

对于雨的生成模型, 为了简化模型以更好地解决去雨问题, 考虑线性组合^[1-2]

$$O = B + R \quad (1)$$

式中, $O \in \mathbf{R}^{M \times N}$ 表示观测图像, $B \in \mathbf{R}^{M \times N}$ 表示清晰图像, 即自然图像, $R \in \mathbf{R}^{M \times N}$ 表示雨线。去雨的目标是将观测图像 O 中的雨线 R 去除, 以得到干净的背景图像 B 。通过观察可以发现, 雨图的生成模型与带噪声的图像的生成模型^[17]形式相同, 考虑到这一点, 去雨过程可借鉴一般的图像恢复问题思路。

1.1 基于最大后验估计的图像去雨建模

当前的图像恢复问题中, 基于概率的方法是一种通用手段, 一方面基于概率的方法能够有效地刻画变量之间的联系, 另一方面, 基于概率的方法易于转换变形, 从而充分利用已知变量来确定未知变量。本文使用概率方法中的最大后验估计来建立模型。

针对去雨问题, 基于最大后验估计的思想, 可以将问题理解为最大化以下公式 (假设背景图像的分布与雨线图像的分布独立)

$$p(B, R | O) \propto p(O | B, R) \cdot p(B) \cdot p(R) \quad (2)$$

也就是说, 研究目标是在已知观测图像 $O \in \mathbf{R}^{M \times N}$ 的情况下, 估计背景图像 $B \in \mathbf{R}^{M \times N}$ 及雨线图像 $R \in \mathbf{R}^{M \times N}$, 而根据式 (2) 的变换, 并从能量的角度可以将问题理解为^[5]

$$\begin{aligned} \min_{B, R} & \|O - B - R\|_2^2 + \Phi(B) + \Psi(R) \\ \text{s. t.} & \quad \forall i \quad 0 \leq B_i, R_i \leq O_i \end{aligned} \quad (3)$$

式中, i 表示像素索引值。 $\Phi(B)$ 表示背景图像的先验知识, $\Psi(R)$ 表示雨线的先验知识。通常情况下, 背景层的先验知识可根据图像恢复问题的常用手段进行刻画, 如全变分 (TV) 模型^[9]等。而雨层的

分布未知,难以进行有效地刻画,为了解决这一问题,本文通过相关优化分裂算法将问题的形式进行转化,以便更好的刻画雨层的先验知识。

1.2 基于优化算法的模型分解

传统的优化分裂算法实质上是将难于直接求解的优化问题,通过转化将问题变为能够易于求解的一系列子问题,该类方法是图像恢复问题中处理优化问题的常用手段。

半二次 (half-quadratic) 优化^[10] 是分裂算法中最简单有效的一种,基本思想是通过辅助变量代替原目标函数中难于求解的变量部分,并在原目标函数上增加衡量辅助变量与被代替变量之间关系的惩罚项(通常使用二范数),然后利用交替优化的思想对新的目标函数进行分裂,得到一系列可直接计算求解的子问题。

拉格朗日乘子法^[11] 及其变形是图像恢复问题中另一种常用的优化分裂算法,与半二次的主要区别在于在原目标函数上添加的惩罚项形式不同,基本的拉格朗日乘子法添加的是一项带乘子项的线性约束,同时这个乘子项在迭代过程中逐步更新。增广拉格朗日乘子法是在原目标函数上添加乘子项的线性约束的基础上,增加与半二次优化相同的二范数惩罚项。从另一个角度看,增广拉格朗日乘子法是在半二次的基础上增加了一项带乘子项的线性约束。通常称基于增广拉格朗日的交替优化方法为 ADMM^[12] (alternative direction method of multiplier), 本文使用 ADMM 的变换形式 Plug-and-Play ADMM。

Plug-and-Play ADMM 是在 ADMM 的基础上进行的形式上的变换,是由 Chan 等人^[13] 提出的一种具有快速收敛性的用于解决图像恢复问题的方法。其基本思想是将 ADMM 的迭代形式变形以使其能够更容易被解释。

通常图像恢复问题解决的是问题

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} f(\mathbf{x}) + \lambda g(\mathbf{x}) \tag{4}$$

式中, \mathbf{x} 表示目标变量,即恢复出的清晰图像, $f(\mathbf{x})$ 表示数据项,与具体的图像恢复问题相关, $g(\mathbf{x})$ 表示关于清晰图像先验知识的先验项, $\lambda > 0$ 用来衡量数据项与先验项之间的权重关系。

针对上述优化问题,采用 Plug-and-Play ADMM 方法后的最终的迭代形式为

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \arg \min_{\mathbf{x}} f(\mathbf{x}) + \frac{\rho}{2} \|\mathbf{x} - \tilde{\mathbf{x}}^{(k)}\|^2 \\ \mathbf{v}^{(k+1)} &= \arg \min_{\mathbf{v}} \lambda g(\mathbf{v}) + \frac{\rho}{2} \|\mathbf{v} - \tilde{\mathbf{v}}^{(k)}\|^2 \\ \bar{\mathbf{u}}^{(k+1)} &= \bar{\mathbf{u}}^{(k)} + (\mathbf{x}^{(k+1)} - \mathbf{v}^{(k+1)}) \end{aligned} \tag{5}$$

式中, k 表示迭代次数, ρ 表示权重系数, \mathbf{v} 表示替代变量, \mathbf{u} 表示乘子项且扩展的乘子项 $\bar{\mathbf{u}} = \frac{\mathbf{u}}{\rho}$, 此外, $\tilde{\mathbf{x}}^{(k)} = \mathbf{v}^{(k)} - \bar{\mathbf{u}}^{(k)}$, $\tilde{\mathbf{v}}^{(k)} = \mathbf{x}^{(k+1)} + \bar{\mathbf{u}}^{(k)}$ 。对于上述公式中的第 2 个子问题,其形式与去噪问题形式相同,故该子问题可视为去噪问题,可使用现成的去噪算法进行求解,这样便体现了 Plug-and-Play 的思想。

根据上述优化方法,将式(3)中的变量 \mathbf{B}, \mathbf{R} 分别用辅助变量 \mathbf{P}, \mathbf{Q} 代替后变为

$$\begin{aligned} \min_{\mathbf{B}, \mathbf{R}} & \|\mathbf{O} - \mathbf{B} - \mathbf{R}\|_2^2 + \Phi(\mathbf{P}) + \Psi(\mathbf{Q}) \\ \text{s. t. } & \mathbf{P} = \mathbf{B}, \mathbf{Q} = \mathbf{R}, \forall i \ 0 \leq B_i, R_i \leq O_i \end{aligned} \tag{6}$$

对式(6)采用 Plug-and-Play ADMM 方法后的迭代公式为

$$\begin{aligned} \{\mathbf{B}^{(k+1)}, \mathbf{R}^{(k+1)}\} &= \arg \min_{\mathbf{B}, \mathbf{R}} \|\mathbf{O} - \mathbf{B} - \mathbf{R}\|_2^2 + \\ & \frac{\rho_B}{2} \|\mathbf{B} - \tilde{\mathbf{B}}^{(k)}\|_2^2 + \frac{\rho_R}{2} \|\mathbf{R} - \tilde{\mathbf{R}}^{(k)}\|_2^2 \\ \text{s. t. } & \forall i \ 0 \leq B_i, R_i \leq O_i \\ \mathbf{P}^{(k+1)} &= \arg \min_{\mathbf{P}} \|\mathbf{P} - \tilde{\mathbf{P}}^{(k)}\|_2^2 + \Phi(\mathbf{P}) \\ \mathbf{Q}^{(k+1)} &= \arg \min_{\mathbf{Q}} \|\mathbf{Q} - \tilde{\mathbf{Q}}^{(k)}\|_2^2 + \Psi(\mathbf{Q}) \\ \bar{\mathbf{S}}^{(k+1)} &= \bar{\mathbf{S}}^{(k)} + (\mathbf{B}^{(k+1)} - \mathbf{P}^{(k+1)}) \\ \bar{\mathbf{T}}^{(k+1)} &= \bar{\mathbf{T}}^{(k)} + (\mathbf{R}^{(k+1)} - \mathbf{Q}^{(k+1)}) \end{aligned} \tag{7}$$

式中, $\bar{\mathbf{S}}, \bar{\mathbf{T}}$ 表示扩展的乘子项, $\tilde{\mathbf{B}}^{(k)} = \mathbf{P}^{(k)} - \bar{\mathbf{S}}^{(k)}$, $\tilde{\mathbf{R}}^{(k)} = \mathbf{Q}^{(k)} - \bar{\mathbf{T}}^{(k)}$, $\tilde{\mathbf{P}}^{(k)} = \mathbf{B}^{(k+1)} + \bar{\mathbf{S}}^{(k)}$, $\tilde{\mathbf{Q}}^{(k)} = \mathbf{R}^{(k+1)} + \bar{\mathbf{T}}^{(k)}$ 。这样一来,原问题中的两部分难于刻画的先验知识,被分裂到了两个具有不同含义的子问题中,而这两个子问题的表达形式与传统的图像恢复中的问题相似,因此可借鉴图像恢复问题的思路进行求解。

对于式(7),其含义是对估计的雨线和背景在观测雨图下的校正,由于是关于目标变量 \mathbf{B}, \mathbf{R} 的凸函数,可直接计算梯度求解,但由于该目标函数带有一个边界约束,故采用带边界约束的 L-BFGS 算法进行求解。

对于式(8),其含义是利用背景图像的先验知识对背景图像的估计,分析发现, $\|\mathbf{P} - \tilde{\mathbf{P}}^{(k)}\|$ 这一项刻画的是模型误差,而在去噪问题中,这一项刻画

的是高斯噪声,基本形式相同,但含义不同,由于形式相同,可以利用高斯噪声来模拟这一项模型误差,这样一来就将 P 的求解转化为了去噪问题,由于这样的模拟是不精确的,所以需要一种刻画自然图像比较强的算法,而不是刻画噪声能力强的算法,也就是说,在恢复过程中,先验项的作用明显大于模型误差项,为此本文采用去噪残差网络进行建模。

对于式(9),其含义是利用雨线的先验知识对雨线进行估计。在这一部分,关键的部分在于雨线的先验知识的估计,即式(9)的后一项 $\Psi(Q)$,本文为了更好地刻画学习雨线的先验知识,采用高斯混合模型对不同的测试图像通过块操作采用 EM 算法对模型中的参数进行学习,这样既避免了对大部分的雨线进行刻画,又保证了结果的精确性。

1.3 基于去噪残差网络对背景建模

在图像恢复问题中,残差网络是一种基于卷积神经网络以残差为基本单元建立的网络结构。Chen 等人^[14]从模型出发建立了一种残差网络 TNRD,该网络一方面通过刻画自然图像的分布,另一方面通过每一步的残差单元的引入有效地解决了图像恢复问题。

对于背景建模部分,一方面其目标在于估计自然图像,与图像去噪问题的目标相同;另一方面式(8)本身具有的形式与图像去噪问题相似。此外,一般图像去噪问题处理的是高斯噪声,而通常情况下高斯分布可以用来模拟模型误差。综合两方面因素,本文采用 TNRD 去噪残差网络对背景进行建模。

TNRD 残差网络的能量函数形式为

$$E^t(u, f) = \sum_{i=1}^{N_k} \sum_{p=1}^N \rho'_i((K_i^t u)_p) + \frac{\lambda}{2} \|Au - f\|_2^2 \quad (11)$$

式中, $\rho'(z) = \phi(z) = \sum_{k=1}^M \omega_{ik} \varphi(\frac{|z - \mu_k|}{\gamma_k})$ 即径向基函数(RBF)核函数的线性组合, $u \in \mathbf{R}^N$ 表示目标变量, f 表示退化的图像, $K_i \in \mathbf{R}^{N \times N}$ 表示具有高度稀疏性的矩阵且 $K_i u \Leftrightarrow k_i * u$, k_i 表示线性滤波器, N_k 表示线性滤波器的数目, λ 表示衡量前一项正则项及后一项数据项之间关系的系数。 A 是与问题相关的线性算子。当问题是图像去噪时, A 是单位矩阵;当问题是图像超分辨率时, A 是降采样算子。针对上述能量函数,利用梯度下降法,即可得到不同问

题对应的迭代过程,接着通过设定损失函数,来训练学习整个过程进而得到不同层对应的参数向量 $(\lambda^t, \phi_i^t, k_i^t)$ 。

利用 TNRD (trainable nonlinear reaction diffusion) 残差网络解决图像去噪问题的迭代过程为

$$u_t = u_{t-1} - \left(\sum_{i=1}^{N_k} \bar{k}_i^t * \phi_i^t(k_i^t * u_{t-1}) + \lambda^t(u_{t-1} - f) \right) \quad (12)$$

式中,为了简化模型,利用 \bar{k}_i^t 代替 K_i^t ,表示将模糊核 k_i^t 旋转 180° 后得到。从式(12)可以看出,每一步的更新其实是在神经网络基本单元(卷积层、非线性)的基础上添加残差单元 $u_{t-1} - f$ 来使得结果进一步精确。

此外,训练过程中的损失函数定义为

$$\ell(u_t^{(s)}, u_{gt}^{(s)}) = \frac{1}{2} \|u_t^{(s)} - u_{gt}^{(s)}\|_2^2 \quad (13)$$

式中, u_{gt} 表示真实图像。

在去噪残差网络 TNRD 训练好的情况下,将 \bar{P} 作为输入,输出为 P ,即得到了当前迭代步基于残差网络对背景的估计。

1.4 基于高斯混合模型对雨线建模

采用基于块学习^[15]的思想通过高斯混合模型来刻画雨线的先验知识。即

$$\Psi(Q) = -\mu \sum_{i=1}^L \lg \cdot g(P_i Q) + \beta \|Q\|_2^2 \quad (14)$$

式中, $\gamma > 0, \beta > 0$ 是平衡其对应项关系的权重系数, P_i 是一个矩阵,用来提取向量 Q 的所有重叠的块中的第 i 块, $g(x) = \sum_{k=1}^K \pi_k(x | \mu_k = 0, \Sigma_k)$ 表示高斯混合模型,其中, π_k 表示权重系数, μ_k 表示均值, Σ_k 表示方差。将上式代入式(9),得

$$Q_i^{(k+1)} = \arg \min_Q \left[\frac{\|Q - \bar{Q}^k\|_2^2 - \mu \sum_{i=1}^L \lg g(P_i Q) + \beta \|Q\|_2^2}{\mu \sum_{i=1}^L \lg g(P_i Q) + \beta \|Q\|_2^2} \right] \quad (15)$$

对于该问题,由于块操作矩阵 P_i 的存在,不能直接求解,因此采用半二次优化构造辅助变量 z 代替变量 $P_i Q$,即得到迭代公式

$$z_i^{(k+1)} = \arg \min_{z_i} \left[\frac{\omega \sum_{i=1}^L \|P_i Q - z_i\|_2^2 - \mu \sum_{i=1}^L \lg g(z_i)}{\mu \sum_{i=1}^L \lg g(z_i)} \right] \quad (16)$$

$$Q^{(k+1)} = \arg \min_Q \left[\frac{\|Q - \tilde{Q}^{(k)}\|_2^2}{\omega \sum_{i=1}^L \|P_i Q - z_i\|_2^2 + \beta \|Q\|_2^2} \right] \quad (17)$$

式(17)是关于 Q 的凸函数,其闭合解形式为

$$Q^{(k+1)} = \frac{\omega \sum_{i=1}^L P_i^T z_i + \tilde{Q}^{(k)}}{\omega \sum_{i=1}^L P_i^T P_i + \beta + 1} \quad (18)$$

由此雨线估计的计算过程为式(16)(18)。

1.5 算法流程

综上所述,本文的算法流程如下:

输入:观测图像 O ,雨层 GMM 模型。

初始化: $B \leftarrow O, R \leftarrow 0$ 。

FOR

利用式(7)更新 $\{B, R\}$;

利用训练好的 TNRD 更新 P ;

利用式(16)(18)更新 Q ;

END

输出:背景图像估计及雨线图像估计。

2 实验

2.1 准备工作

由于图像去雨问题的研究尚不成熟,因此,作为基准的数据库有限,本文采用的合成数据集为 Li 等人^[5]所使用的数据库,该数据库基于 Garg 等人^[16]的雨线仿真过程合成图像。

训练数据集取自伯克利大学分割数据集 (BSD)^[17]中的 400 幅图像,同时为了加速训练将其裁剪为 180×180 大小。相关参数设置为采用 24 个大小为 5×5 的滤波器,训练的阶段为 8,噪声强度为 15,选择的高斯 RBF 核的个数为 63,训练过程中的优化算法采用 LBFGS (limited-memory broyden-fletcher-goldfarb-shanno),其最大迭代次数为 200。

为了更好地验证本文提出的算法的精确性及优势,与 3 种基于模型的算法及两种基于深度网络的方法进行比较,这 5 种算法分别为:

- 1) 基于图像分解的方法^[1] (简称 ID);
- 2) 基于稀疏编码的方法^[4] (简称 DSC);
- 3) 基于层先验的方法^[5] (简称 LP);
- 4) 基于深度卷积神经网络的方法^[6] (简称 Der-

ainNet);

5) 基于深度残差网络的方法^[8] (简称 Detail-Net)。

2.2 合成数据集 Rain12 对比实验

根据 2.2 节所述准备工作,进行实验得到的实验结果如表 1、图 1 所示,图 1 为 Rain12 中第 1,2,4,7 帧的可视效果及 SSIM 值对比。

首先,将基于模型的算法 ID、DSC、LP 与基于深度网络的算法 DerainNet、DetailNet 对比,可以发现,基于模型的算法在去除雨线效果上有明显的优势,而基于深度网络的算法在保留背景细节上则更有优势,从这一点也可以看出,将基于模型的算法与基于深度网络的算法相结合,融合两种方法的各自优势是具有重要意义的。

从图 1、表 1 可以看出,与基于模型的算法相比,无论是定量上的结构相似性 (SSIM) 值,还是定性上的可视效果,本文算法均优于其他算法。从图中选定的矩形区域可以看出,LP 去除雨线明显,但根本缺点在于估计出的背景被平滑变得模糊,而本文算法则不仅去除雨线明显而且背景的细节部分也得到了最大化的保留。与基于深度学习的方法相比,数值上本文算法的 SSIM 值低于 DetailNet,但从可视效果上看,尤其是从选定的矩形区域中可以看出,DetailNet 的雨线去除效果并不理想,估计出的背景中还有部分的雨线存在,分析可以发现,一方面,DetailNet 是通过简化深度残差网络的学习过程提出的一种深度细节网络,该网络结构着重处理图像中存在的细节部分,虽然大部分细节均为背景图像的细节,但实际上雨线中的部分信息也将会被视为细节处理,这样一来就不能够保证雨线去除干净,而 SSIM 值比较高则是由于 SSIM 值本身刻画的便是两幅图像的结构相似性,而细节部分对于 SSIM 值的影响比较大。另一方面,关注深度神经网络本身,由于网络结构固定后,测试结果完全依赖于训练的好坏,而影响训练的直接因素便是训练数据,一般情况下训练数据越多,测试结果越好。但对于去雨问题,由于雨图的形成过程存在着很多的未知因素,因此数据是很难获取和对数据进行学习的,而影响深度学习性能的直接因素便是数据,所以利用网络解决去雨问题很难实现泛化。

从 DetailNet 出现的结果也可以看出,衡量单幅图像去雨的衡量标准应该综合考虑定量和定性分

表 1 不同的去雨方法在数据集 Rain12 上的 SSIM 值对比
Table 1 SSIM results among different rain removal methods on Rain12

算法	1	2	3	4	5	6	7	8	9	10	11	12	平均
ID	0.73	0.79	0.83	0.76	0.62	0.73	0.82	0.77	0.73	0.74	0.63	0.76	0.74
DSC	0.82	0.86	0.75	0.95	0.92	0.93	0.94	0.80	0.90	0.84	0.89	0.82	0.87
LP	0.89	0.93	0.92	0.94	0.90	0.95	0.96	0.90	0.91	0.90	0.86	0.92	0.92
DerainNet	0.87	0.92	0.88	0.95	0.92	0.95	0.97	0.85	0.93	0.87	0.89	0.89	0.91
DetailNet	0.92	0.95	0.91	0.98	0.95	0.97	0.98	0.90	0.96	0.92	0.93	0.92	0.94
本文	0.89	0.94	0.92	0.96	0.91	0.96	0.97	0.89	0.93	0.89	0.89	0.90	0.92

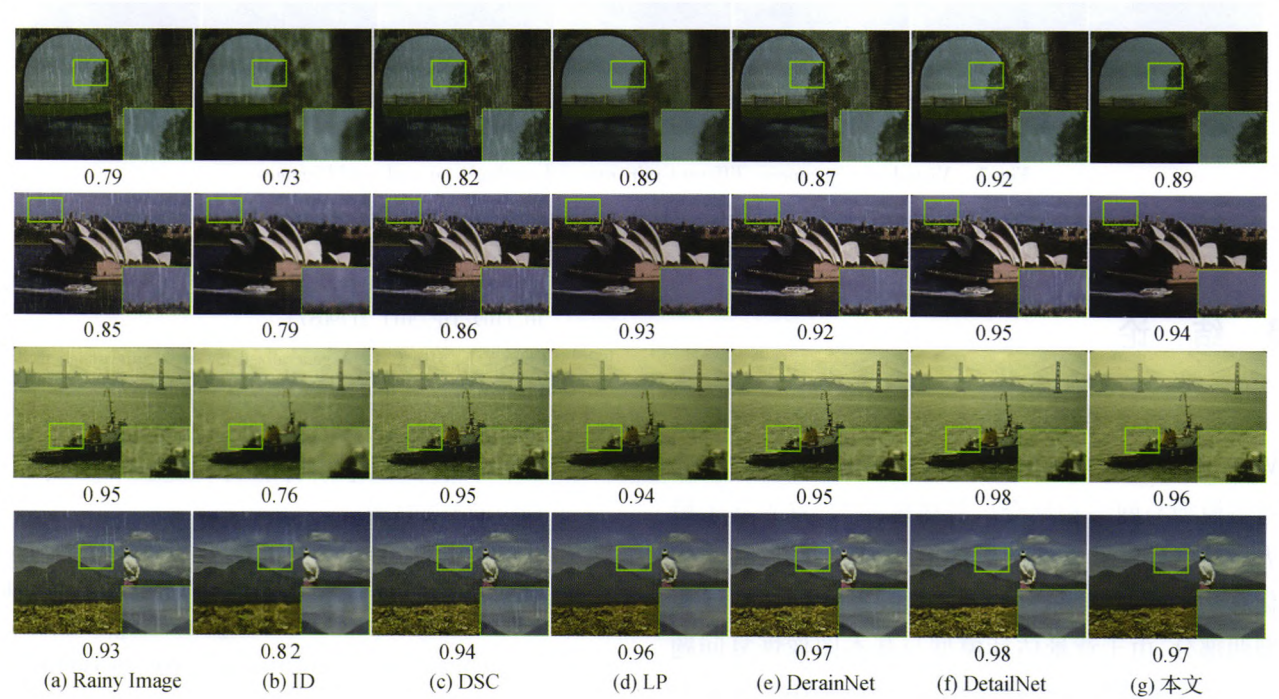


图 1 不同的去雨方法在数据集 Rain12 上的可视效果及 SSIM 值对比

Fig. 1 Visual results and SSIM results on Rain12 among different rain removal methods
((a) Rainy Image; (b) ID; (c) DSC; (d) LP; (e) DerainNet; (f) DetailNet; (g) ours))

析,只注重定量分析或只注重定性分析都不是衡量算法的最好方式。

总的来说,本文提出的算法将从问题本身出发具有一定泛化能力的模型与以数据驱动的网络相结合,有效地将基于模型的算法的去除雨线的优势与基于深度网络的算法的估计清晰背景的优势融合,巧妙地解决了图像去雨问题,不仅去除雨线比较彻底,同时保证了背景的细节部分不被损失,很大程度上实现了二者之间的平衡。

2.3 真实图像对比实验

为了验证本文算法在真实数据上的有效性,将

本文算法应用在真实的雨图上,并与 5 种算法进行对比,结果如图 2 所示。

通过图 2 发现,本文算法在真实图像上能够有效去除雨线,同时最大化保留背景图像的信息,而其他基于模型的方法会在去雨的同时损失大量的背景图像的信息,导致估计出的背景图像模糊,而基于深度神经网络的 DerainNet 及 DetailNet 对雨线比较小的雨图去除效果比较好,对于雨线比较大的雨图去除效果较差,相比之下本文算法的泛化能力更强,对不同程度的雨线均能达到不错的去除效果。

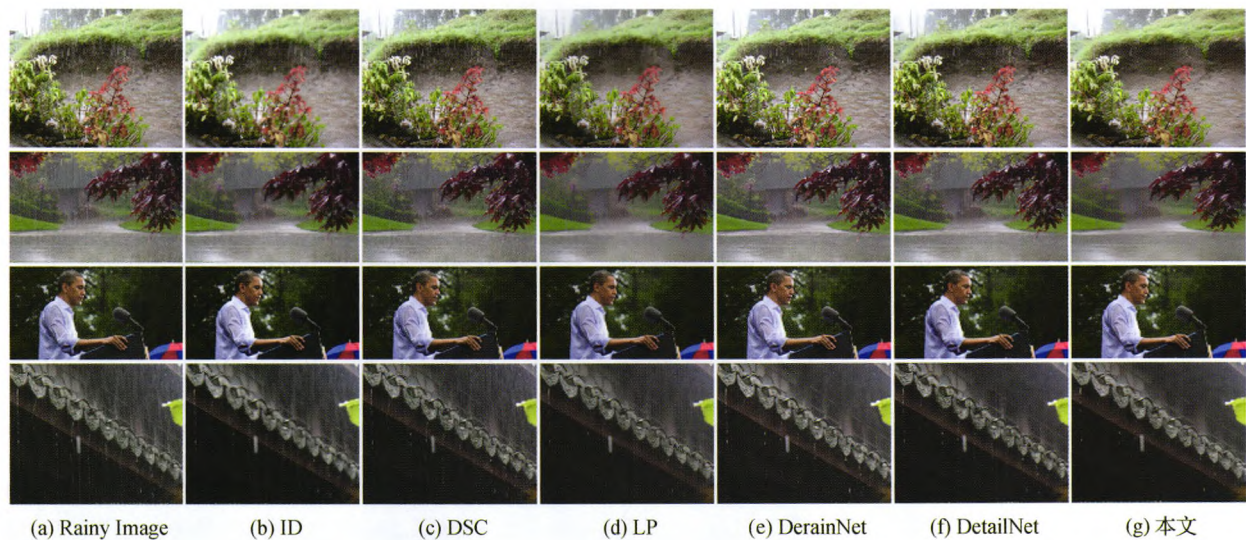


图 2 不同的去雨方法在真实雨图上的可视效果对比

Fig. 2 Visual results among different rain removal methods on real world images
((a) Rainy Image; (b) ID; (c) DSC; (d) LP; (e) DerainNet; (f) DetailNet; (g) ours)

3 结 论

针对图像去雨问题,本文提出可学习的混合MAP网络,综合考虑模型与网络各自的优势,有效地将模型与网络相结合。具体思路为,首先基于最大后验估计建立去雨问题的能量模型,然后利用优化算法将模型分解为背景估计模型和雨线估计模型两部分,由于背景估计模型与基本图像恢复问题图像去噪公式形式和目标相同,因此利用去噪残差网络对该问题求解,对于雨线估计模型,由于雨线数据本身存在大量不确定性,采用高斯混合模型对当前测试图像的雨线先验进行建模。最后在合成数据集 Rain12 及真实雨图上进行实验,通过综合考虑定量分析和定性分析,并与 3 种基于模型的方法及两种基于深度学习的方法相比,显示出本文算法的优势,同时也说明将传统方法与深度学习结合是一种解决图像恢复问题的有效途径。

未来工作包括:通过构造下降方向等策略进一步提升算法效率;考虑将雨和雾联合去除,并借鉴本文思路进行求解。

参考文献 (References)

[1] Kang L W, Lin C W, Fu Y H. Automatic single-image-based rain streaks removal via image decomposition[J]. IEEE Transac-

tions on Image Processing, 2012, 21(4): 1742-1755. [DOI: 10.1109/TIP.2011.2179057]
[2] Chen Y L, Hsu C T. A generalized low-rank appearance model for spatio-temporally correlated rain streaks[C]//Proceedings of 2013 IEEE International Conference on Computer Vision. Sydney, NSW, Australia: IEEE, 2013: 1968-1975. [DOI: 10.1109/ICCV.2013.247]
[3] Kim J H, Lee C, Sim J Y, et al. Single-image deraining using an adaptive nonlocal means filter[C]//Proceedings of the 20th IEEE International Conference on Image Processing. Melbourne, VIC, Australia: IEEE, 2013: 914-917. [DOI: 10.1109/ICIP.2013.6738189]
[4] Luo Y, Xu Y, Ji H. Removing rain from a single image via discriminative sparse coding[C]//Proceedings of 2015 IEEE International Conference on Computer Vision. Santiago, Chile: IEEE, 2015: 3397-3405. [DOI: 10.1109/ICCV.2015.388]
[5] Li Y, Tan R T, Guo X J, et al. Rain streak removal using layer priors[C]//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA: IEEE, 2016: 2736-2744. [DOI: 10.1109/CVPR.2016.299]
[6] Fu X Y, Huang J B, Ding X H, et al. Clearing the skies: a deep network architecture for single-image rain removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956. [DOI: 10.1109/TIP.2017.2691802]
[7] Yang W H, Tan R T, Feng J S, et al. Deep joint rain detection and removal from a single image[C]//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 1357-1366. [DOI: 10.1109/CVPR.2017.183]
[8] Fu X Y, Huang J B, Zeng D L, et al. Removing rain from single images via a deep detail network[C]//Proceedings of 2017

IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 3855-3863. [DOI: 10.1109/CVPR.2017.186]

[9] Wang Y L, Yang J F, Yin W T, et al. A new alternating minimization algorithm for total variation image reconstruction [J]. SIAM Journal on Imaging Sciences, 2008, 1 (3): 248-272. [DOI: 10.1137/080724265]

[10] Geman D, Yang C D. Nonlinear image recovery with half-quadratic regularization [J]. IEEE Transactions on Image Processing, 1995, 4 (7): 932-946. [DOI: 10.1109/83.392335]

[11] Glowinski R, Le Tallec P. Augmented Lagrangian and Operator-Splitting Methods in Nonlinear Mechanics [M]. Philadelphia, Pennsylvania: Society for Industrial and Applied Mathematics, 1989.

[12] Boyd S, Parikh N, Chu E, et al. Distributed optimization and statistical learning via the alternating direction method of multipliers [J]. Foundations and Trends® in Machine Learning, 2011, 3 (1): 1-122. [DOI: 10.1561/22000000016]

[13] Chan S H, Wang X R, Elgendy O A. Plug-and-play ADMM for image restoration: Fixed-point convergence and applications [J]. IEEE Transactions on Computational Imaging, 2017, 3 (1): 84-

98. [DOI: 10.1109/TCI.2016.2629286]

[14] Chen Y J, Pock T. Trainable nonlinear reaction diffusion: a flexible framework for fast and effective image restoration [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39 (6): 1256-1272. [DOI: 10.1109/TPAMI.2016.2596743]

[15] Zoran D, Weiss Y. From learning models of natural image patches to whole image restoration [C] // Proceedings of 2011 IEEE International Conference on Computer Vision. Barcelona, Spain: IEEE, 2011: 479-486. [DOI: 10.1109/ICCV.2011.6126278]

[16] Garg K, Nayar S K. Photorealistic rendering of rain streaks [J]. ACM Transactions on Graphics, 2006, 25 (3): 996-1002. [DOI: 10.1145/1141911.1141985]

[17] Martin D, Fowlkes C, Malik J, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics [C] // Proceedings of 8th IEEE International Conference on Computer Vision. Vancouver, BC, Canada: IEEE, 2001: 416-423. [DOI: 10.1109/ICCV.2001.937655]